RAPPORT DE PROJET

Tarification en Assurance Automobile

Application des méthodes de Machine Learning à la prédiction de la prime pure

Réalisé par : **Doriane Vofo** | Année 2025–2026

Table des matières

1 Introduction **2**

2 Données et Analyse Exploratoire **2**

2.1 Présentation du jeu de données 2

2.2 Statistiques descriptives et distributions 2

2.3 Taux de sinistralité et analyse par variable catégorielle 3

3 Préparation des Données **3**

4 Modèle de Fréquence **4**

4.1 Régression pénalisée — Ridge et Lasso 4

4.2 Arbre CART 4

4.3 Forêt aléatoire 4

4.4 Gradient Boosting (HistGradientBoosting) 5

4.5 Tableau comparatif — Modèle de fréquence 5

5 Modèle de Sévérité **5**

5.1 Justification de la transformation logarithmique 5

5.2 Résultats des modèles de sévérité 6

5.3 Variables importantes : fréquence vs sévérité 6

6 Prime Pure et Analyse de Segmentation **6**

6.1 Distribution des primes pures prédites 7

6.2 Graphe de Lorenz actuariel — Segmentation par déciles 7

6.3 Rapport de concentration — Top 1 % 7

7 Discussion Critique **8**

7.1 Limites de l'approche fréquence × sévérité 8

7.2 Contraintes réglementaires — RGPD et non-discrimination 8

7.3 Interprétabilité vs performance prédictive 8

8 Conclusion **9**

1 Introduction

La tarification est le cœur du métier actuariel. En assurance automobile de responsabilité civile (RC), il s'agit d'estimer la prime que doit payer chaque assuré en fonction de son exposition au risque. Ce projet explore dans quelle mesure les méthodes de machine learning — régression pénalisée, arbres de décision, méthodes d'ensemble — permettent d'améliorer la qualité prédictive tout en restant interprétables pour un usage opérationnel.

Le problème est décomposé en deux sous-modèles : un modèle de fréquence qui prédit le nombre de sinistres par unité d'exposition, et un modèle de sévérité qui prédit le coût moyen conditionnel d'un sinistre. La prime pure estimée est leur produit :

$$\hat{\pi} = \hat{\lambda} \times \hat{s} \qquad \text{(fréquence prédite} \times \text{sévérité prédite)}$$

Cette décomposition est fondamentale : les déterminants de la fréquence (comportement du conducteur, contexte urbain) diffèrent de ceux de la sévérité (valeur du véhicule, type de sinistre), ce qui justifie la modélisation séparée.

2 Données et Analyse Exploratoire

2.1 Présentation du jeu de données

Le jeu de données freMTPL2, issu du marché français de l'assurance RC automobile, comprend deux tables :

Table	**Dimensions**	**Description**
freMTPL2freq	678 013 × 12	Une ligne = une police (IDpol, ClaimNb, Exposure, variables profil)
freMTPL2sev	26 639 × 2	Une ligne = un sinistre (IDpol, ClaimAmount)

Les deux tables sont sans valeurs manquantes. La table de fréquence ne présente aucun doublon (chaque police est unique). La table de sévérité contient 261 doublons — certains assurés ayant déclaré le même sinistre plusieurs fois — sans impact sur les modèles puisqu'une agrégation par moyenne est réalisée.

2.2 Statistiques descriptives et distributions

Variable	**Moyenne**	**Médiane**	**Min**	**Max**	**Observation clé**
ClaimNb	0.053	0	0	16	Très asymétrique → loi de Poisson
Exposure	0.529	0.49	0.003	2.01	Durée moy. ≈ 6 mois
BonusMalus	59.76	50	50	230	Majorité au bonus max (50)
DrivAge	45.5	44	18	100	Pic à 30–50 ans
Density	1 792	393	1	27 000	Très asymétrique → log-transform
ClaimAmount	2 087	1 128	1	4 075 401	Queue lourde → log-transform

Interprétation : ClaimNb est très asymétrique à droite — une vaste majorité de zéros confirme que ClaimNb suit une loi de Poisson de faible paramètre. La durée des contrats est en moyenne de 6 mois ; rares sont ceux qui vont au-delà d'un an. BonusMalus est concentré autour de 50 (bonus maximal) avec une longue queue droite vers les conducteurs malussés. ClaimAmount présente une asymétrie extrême (min = 1 €, max ≈ 4 M€) avec une majorité de petits sinistres, ce qui impose la transformation logarithmique.

2.3 Taux de sinistralité et analyse par variable catégorielle

Le taux global $\bar{\lambda} = \sum \text{ClaimNb} / \sum \text{Exposure} \approx 0.1006$: environ 10 sinistres pour 100 années-contrats. Environ 95 % des polices n'ont déclaré aucun sinistre, et moins de 1 % en ont déclaré deux ou plus — déséquilibre prononcé justifiant le split stratifié.

L'analyse du taux brut par modalité révèle :

— **Area :** gradient régulier de A (rural) à F (très urbain), avec un écart d'environ 2× entre les extrêmes. Variable la plus différenciante.

— **Region :** forte variabilité régionale (R94, R21, R11 en tête). Deuxième variable la plus discriminante.

— **VehGas :** les véhicules Regular ont un taux légèrement supérieur aux Diesel.

— **VehBrand :** hétérogénéité notable, certaines marques (B11, B12) bien au-dessus de la moyenne.

3 Préparation des Données

La préparation suit un protocole rigoureux pour éviter le data leakage : toutes les transformations apprises (encodages, scalers) sont ajustées sur le train uniquement, puis appliquées au test.

Étapes de préparation	**Résultat du split**
① Troncature : DrivAge → [18, 90], BonusMalus → [50, 300] ② Transformation : LogDensity = log(Density) ③ Variable cible : FreqRate = ClaimNb / Exposure ④ Split stratifié 80/20 sur ClaimNb_bin ⑤ Target encoding de Region (sur train seul) ⑥ One-Hot Encoding : Area, VehBrand, VehGas	Train : 542 410 polices (80 %) Test : 135 603 polices (20 %) Taux sinistre Train : 0.0502 Taux sinistre Test : 0.0502 ✓ 22 régions encodées X final : 22 features (6 num. + 16 OHE)

Le split stratifié est indispensable : avec ∼95 % de zéros, un split aléatoire non stratifié risquerait de concentrer les sinistres dans le train, rendant le test non représentatif. La stratification sur ClaimNb_bin garantit que les proportions sont identiques dans les deux ensembles.

4 Modèle de Fréquence

L'objectif est de prédire le taux $\lambda_i = \text{ClaimNb}_i/\text{Exposure}_i$ pour chaque police. Cinq méthodes sont comparées à une baseline (prédiction constante = $\bar{\lambda}$ du train).

4.1 Régression pénalisée — Ridge et Lasso

Ridge (Tikhonov, 1943) minimise :

$$L(\beta) = \sum w_i(y_i - X\beta)^2 + \alpha \sum \beta^2$$

(pénalité L_2 contractant les coefficients sans les annuler). Lasso (Tibshirani, 1996) remplace la pénalité par $\alpha \sum |\beta|$ (L_1), ce qui annule exactement certains coefficients — sélection de variables implicite. Les deux nécessitent une normalisation préalable.

Chemin de régularisation Lasso : les variables « meurent » les unes après les autres à des seuils d'énergie différents (propriété géométrique de la norme L_1). BonusMalus résiste le plus longtemps : c'est le prédicteur le plus stable. Les modalités OHE peu représentées de VehBrand sont éliminées en premier. L'α optimal retenu (0.000202) élimine uniquement Area_B et Area_F (2 variables sur 22).

4.2 Arbre CART

CART (Breiman, 1984) partitionne récursivement l'espace en minimisant :

$$\text{Gain}(j, s) = \text{Var}(y_n) - \left[\frac{n_-}{n}\text{Var}(y_-) + \frac{n_+}{n}\text{Var}(y_+)\right]$$

La première coupure de l'arbre (max_depth=4) porte sur BonusMalus — le descripteur le plus puissant. À depth=8, la RMSE_train s'effondre tandis que la RMSE_test stagne : surapprentissage. En tarification, un arbre trop profond crée des micro-niches avec trop peu d'assurés, générant des tarifs arbitraires.

4.3 Forêt aléatoire

Breiman (2001) combine B arbres entraînés sur des sous-échantillons bootstrap, avec seulement $m \approx \sqrt{p}$ features par nœud :

$$\hat{y}_{RF} = \frac{1}{B}\sum_{b=1}^{B} T_b(x)$$

Ces deux sources d'aléa décorrèlent les arbres, réduisant la variance sans augmenter le biais. L'erreur OOB (Out-Of-Bag) est une estimation non biaisée de la généralisation, calculée sur les observations non tirées dans chaque bootstrap. Le plateau est atteint vers 120–140 arbres ; le modèle final utilise 160 arbres.

Importance des variables (Gini) : VehAge (29,4 %) et BonusMalus (19,9 %) écrasent tous les autres prédicteurs — le comportement passé est le meilleur miroir du risque futur. LogDensity (8,9 %) et VehPower (8,3 %) complètent le tableau. 9 variables sur 10 sont communes au top-10 du Lasso : forte cohérence entre les deux approches.

4.4 Gradient Boosting (HistGradientBoosting)

Le Gradient Boosting construit séquentiellement des correcteurs (Weak Learners) sur les résidus du modèle courant :

$$F_m(x) = F_{m-1}(x) + \eta \times T_m(x)$$

Le learning rate $\eta = 0.1$ force de nombreux petits pas prudents plutôt que quelques grands sauts risqués. La sélection des hyperparamètres par GridSearchCV 5-fold retient : learning_rate = 0.10, max_depth = 5, max_iter = 200 (135 itérations effectives avec early stopping). La courbe de perte décroît de manière très fluide au fil des itérations.

4.5 Tableau comparatif — Modèle de fréquence

Méthode	RMSE test	Déviance Poisson	Gain / Baseline
Gradient Boosting	0.714307	41 167.71	0.97 % ← meilleur
CART (depth = 8)	0.714412	41 513.30	0.96 %
Random Forest	0.715075	41 350.48	0.86 %
Ridge	0.719769	43 519.70	0.21 %
Lasso	0.719771	43 487.71	0.21 %
Baseline	0.721310	44 795.51	0.00 % (référence)

Interprétation : Le Gradient Boosting surclasse nettement tous les autres modèles. La Déviance de Poisson est la métrique de référence en assurance pour les données de comptage. Réduire la déviance de 44 795 (Baseline) à 41 168 (HGB) se traduit, à l'échelle du portefeuille, par une réduction des erreurs de sous-tarification (pertes financières) et de sur-tarification (fuite des bons clients). Ridge et Lasso, moins performants, offrent en contrepartie une interprétabilité directe des coefficients.

5 Modèle de Sévérité

La sévérité modélise $E[S \mid N \geq 1]$ — le coût moyen conditionnel d'un sinistre, sur un sous-ensemble restreint (≈ 4 % des polices) :

Train sévérité : 19 945 polices (3,68 % du train) | Test sévérité : 4 999 polices (3,69 % du test)

AvgSeverity — Moyenne : 2 087 € | Médiane : 1 128 € | Écart-type : 31 980 € | Max : 4 075 401 €

5.1 Justification de la transformation logarithmique

On modélise log(AvgSeverity) plutôt qu'AvgSeverity directement pour trois raisons fondamentales :

— **Corriger l'asymétrie extrême (Heavy Tail) :** quelques sinistres corporels graves (centaines de milliers d'euros) écraseraient le modèle sans la transformation. Le log ramène les ordres de grandeur à une échelle condensée.

— **Stabiliser la variance (Homoscédasticité) :** en assurance, la variabilité d'un sinistre croît avec son montant potentiel. Le log stabilise cette variance, rapprochant les résidus d'une distribution normale.

— **Effets multiplicatifs :** modéliser $\log(S) = \beta_0 + \beta_1 X_1 + \ldots$ signifie que chaque facteur agit par coefficient multiplicateur sur le coût (ex : rouler en zone urbaine augmente le coût de 15 %).

Correction du biais log-normal : Si $Y = \log(S) \sim \mathcal{N}(\mu, \sigma^2)$, alors

$$E[S] = \exp\left(\mu + \frac{\sigma^2}{2}\right) \neq \exp(\mu).$$

La correction $\sigma^2/2$ est appliquée à chaque modèle (σ^2 estimé sur les résidus du train) pour éviter une sous-estimation systématique de la sévérité.

5.2 Résultats des modèles de sévérité

Modèle	**σ^2 résid. (train)**	**Correction**	**RMSE (log)**	**RMSE (€ orig.)**
Random Forest	1.66354	exp(+0.83177)	1.3184	9 085 € ← meilleur
Gradient Boosting	1.70869	exp(+0.85435)	1.3195	9 089 €
Lasso	1.76140	exp(+0.88070)	1.3218	9 086 €

Les trois méthodes sont très proches en sévérité (écart RMSE_log < 0.004). La forte variabilité intrinsèque des montants de sinistres limite la prédictibilité au-delà d'un certain seuil. La Random Forest est légèrement meilleure et est retenue pour la prime pure.

5.3 Variables importantes : fréquence vs sévérité

La comparaison des importances entre les deux modèles révèle une dissociation fondamentale :

FRÉQUENCE — RF	**SÉVÉRITÉ — RF**
VehAge : 29.4 % BonusMalus : 19.9 % DrivAge : 11.2 % LogDensity : 8.9 % VehPower : 8.3 % → Comportement du conducteur	VehPower : dominant Region : fort BonusMalus : modéré VehAge : modéré VehBrand : présent → Type de véhicule / sinistre

Un conducteur avec un fort BonusMalus crée plus d'accidents (fréquence élevée) ; un véhicule puissant génère des accidents plus coûteux (sévérité élevée). Cette dissociation confirme que la décomposition fréquence × sévérité est pertinente et nécessaire.

6 Prime Pure et Analyse de Segmentation

Les modèles retenus sont HGB pour la fréquence et RF pour la sévérité. La prime pure est calculée pour toutes les polices du test, y compris celles sans sinistre historique.

6.1 Distribution des primes pures prédites

Statistiques	Interprétation
Moyenne : 229,24 €/an Médiane : 149,17 €/an Minimum : 0,00 €/an Maximum : 5 773,23 €/an Quantile 95 % : 734,69 €/an Quantile 99 % : 1 627,81 €/an	Moyenne > Médiane : distribution asymétrique droite. Quelques polices très risquées tirent la moyenne vers le haut. 95 % du portefeuille < 735 €/an. 1 % seulement dépasse 1 628 €/an. Le modèle surtaxe précisément les risques extrêmes tout en protégeant le portefeuille.

6.2 Graphe de Lorenz actuariel — Segmentation par déciles

Le graphe de Lorenz actuariel compare, décile par décile de prime prédite, la prime prédite vs la prime observée. Une courbe proche de la diagonale indique un bon classement des risques.

Décile	Prime prédite moy.	Prime observée moy.	N polices	N sinistres	Écart diagonal
D1 (plus faibles)	59 €	217 €	13 561	313	Au-dessus ↑
D2	94 €	137 €	13 560	474	Au-dessus ↑
D3	113 €	501 €	13 560	517	Au-dessus ↑
D4–D9	129–218 €	138–231 €	81 361	3 869	Proches ✓
D10 (plus élevés)	≫ 218 €	variable	13 560	croissant	En dessous ↓

Coefficient de Gini actuariel = 0.3426. En tarification IARD, un Gini de 0,34 sur la prime pure finale est un excellent résultat : le modèle combiné HGB × RF sépare efficacement les assurés à faible risque des assurés à haut risque. Points au-dessus de la diagonale (D1–D3) : légère surestimation des petits risques. Point en dessous (D10) : légère sous-estimation des gros risques.

6.3 Rapport de concentration — Top 1 %

Résultat clé

Seuil P99 prime prédite : 1 627,81 €/an | Nombre de polices top 1 % : 1 357
Taux sinistralité top 1 % : 1.11057 | Taux sinistralité global : 0.10104

Rapport de concentration : 1.11057/0.10104 = 10,99× ≈ 11×

→ Le top 1 % identifié par le modèle est 11 fois plus sinistré que la moyenne du portefeuille.

Ce ratio de 11× mesure la capacité discriminante du modèle : un modèle naïf (Baseline) donnerait un ratio proche de 1. En pratique, identifier avec précision les 1 % les plus risqués est crucial pour éviter la sélection adverse et garantir la solvabilité de l'assureur.

7 Discussion Critique

7.1 Limites de l'approche fréquence × sévérité

— **Hypothèse d'indépendance :** L'approche multiplicative $\lambda \times s$ suppose que fréquence et sévérité sont indépendantes — ce qui est rarement vérifié. Un conducteur imprudent peut à la fois avoir plus de sinistres ET des sinistres plus graves.

— **Hétérogénéité intra-police :** Agréger les sinistres par moyenne efface l'information sur leur distribution interne. Trois sinistres de 500 € et un sinistre de 1 500 € donnent la même sévérité moyenne mais des profils de risque différents.

— **Polices sans historique :** Les prédictions reposent entièrement sur les features observées, sans information comportementale réelle pour les assurés n'ayant jamais déclaré de sinistre.

7.2 Contraintes réglementaires — RGPD et non-discrimination

Dans de nombreuses législations, l'utilisation du sexe comme facteur de tarification est interdite (directive européenne Test-Achats, 2012). Or les algorithmes complexes (forêts aléatoires, boosting) peuvent reconstruire une variable interdite à partir de variables autorisées — c'est l'effet de proxy. Par exemple, croiser le type exact de véhicule, la profession et la zone géographique peut permettre au Gradient Boosting de « deviner » le sexe de l'assuré. L'actuaire doit auditer ses modèles pour s'assurer qu'aucune combinaison de variables autorisées ne recrée artificiellement l'effet d'une variable interdite.

7.3 Interprétabilité vs performance prédictive

En actuariat, l'interprétabilité n'est pas seulement académique — c'est une nécessité opérationnelle et réglementaire, articulée autour de quatre piliers :

— **Conformité réglementaire :** Le régulateur exige des tarifs justifiables. Un Lasso permet de sortir une équation claire (« chaque point de BonusMalus supplémentaire augmente la prime de X€ »). Un Gradient Boosting produit une combinaison opaque de centaines d'arbres, impossible à auditer visuellement.

— **Explicabilité au client :** Face à une hausse de prime de 30 %, le conseiller doit pouvoir expliquer pourquoi. Un modèle boîte noire produit un tarif individualisé au centime près mais inexplicable, détruisant la confiance client.

— **Maîtrise des biais :** Un modèle ML opportuniste exploitera toute corrélation dans les données d'apprentissage, même absurde (ex : voitures rouges = moins d'accidents par pur hasard). Un actuaire analysant les coefficients d'un Lasso ou d'un arbre CART repère immédiatement ces anomalies.

— **Stabilité dans le temps :** Les modèles complexes sont instables face aux évolutions du marché (inflation, comportements). Un Lasso parcimonieux capture uniquement les grandes tendances et garantit une meilleure stabilité des tarifs dans le futur.

8 Conclusion

Ce projet a démontré comment les méthodes de machine learning peuvent être appliquées avec succès à la tarification en assurance automobile, en suivant l'architecture classique fréquence × sévérité.

Axe	**Résultat principal**
Meilleur modèle fréquence	Gradient Boosting : RMSE = 0.7143 | Déviance = 41 168 | +0.97 % vs Baseline
Meilleur modèle sévérité	Random Forest : RMSE_log = 1.3184 | correction biais $\sigma^2/2$ appliquée
Prime pure (HGB × RF)	Moyenne 229 €/an | Gini actuariel = 0.3426 | Rapport concentration = 11×
Variable clé fréquence	BonusMalus + VehAge (comportement conducteur)
Variable clé sévérité	VehPower + Region (type de sinistre)

La dissociation entre les drivers de fréquence et de sévérité justifie pleinement l'approche en deux temps. Un rapport de concentration de 11× sur le top 1 % des risques constitue un résultat opérationnel significatif, confirmant que le modèle discrimine efficacement les profils à fort risque des profils courants.

Le vrai défi en assurance ne réside pas dans la maximisation aveugle de la performance prédictive, mais dans le compromis performance / interprétabilité / conformité réglementaire. Associer la puissance du Gradient Boosting à des outils d'explicabilité post-hoc (valeurs SHAP) constitue la voie la plus prometteuse pour répondre simultanément à ces trois exigences.

Message clé : le Machine Learning en assurance crée de la valeur non pas en réduisant marginalement la RMSE, mais en identifiant les 1 % de polices 11× plus risquées que la moyenne — permettant une tarification juste, équilibrée et financièrement saine pour l'ensemble du portefeuille.